

Previsão Multivariada da Bovespa com Deep Learning

Documentação técnica do Trabalho de Conclusão

Flavio Renan Sant'Anna

github.com/FlavioR77/Previsao-Bovespa-Multivariada

Python 3.12 · TensorFlow/Keras · scikit-learn · yfinance

1. Visão geral do projeto

Este trabalho aplica técnicas de Deep Learning para prever o comportamento do índice Bovespa (^BVSP) a partir de um conjunto de variáveis macroeconômicas globais e domésticas. A premissa central é simples: a bolsa brasileira não opera de forma isolada. Ela responde continuamente a movimentos de outras bolsas, ao preço das commodities que sustentam boa parte das empresas listadas e, de forma bastante direta, à curva de juros do próprio país.

Modelos univariados clássicos, como ARIMA e SARIMAX, projetam a série olhando apenas para o próprio histórico do índice e pressupõem relações lineares. Redes neurais recorrentes, ao contrário, conseguem absorver várias séries simultaneamente e capturar interações não lineares entre elas. É essa diferença que o projeto explora.

O projeto se desenvolve em três estratégias complementares de previsão:

Abordagem	O que ela entrega
Regressão diária	Prevê o ponto exato de fechamento do Ibovespa para o próximo dia útil
Classificação em 3 classes	Prevê o cenário direcional: Alta, Neutro ou Baixa
Classificação em 5 classes	Prevê o cenário com granularidade de volatilidade: Alta Forte, Leve Alta, Neutro, Leve Baixa e Baixa Forte

As três convivem no mesmo repositório porque respondem a perguntas diferentes. A regressão responde "quanto"; a classificação responde "para onde" e "com que intensidade" — e é essa segunda pergunta que costuma ser mais acionável na prática.

2. Dados e variáveis

A base é montada automaticamente a cada execução, via biblioteca `yfinance`, com três anos de histórico de cotações de fechamento. Nenhum dado é armazenado no repositório: os notebooks baixam a série atualizada no momento em que rodam.

```
tickers = {
    'Bovespa':      '^BVSP',
    'Dolar':        'BRL=X',
    'SP500':        '^GSPC',
    'Shanghai':     '000001.SS',
    'Petroleo':     'BZ=F',
    'Minerio':      'TI0=F',
    'Ouro':         'GC=F',
    'Juros_BR':     'LFTS11.SA',
    'Inflacao_BR':  'IMAB11.SA'
}
```

Variável	Ticker	Descrição
Bovespa	^BVSP	Índice de referência brasileiro — alvo da previsão
Dólar	BRL=X	Cotação USD/BRL
S&P 500	^GSPC	Índice das 500 maiores empresas dos EUA
Shanghai	000001.SS	Bolsa da China
Petróleo	BZ=F	Contrato futuro Brent
Minério de Ferro	TIO=F	Contrato futuro de minério
Ouro	GC=F	Contrato futuro de ouro
Juros BR	LFTS11.SA	ETF atrelado à Selic — custo de oportunidade e liquidez diária
Inflação BR	IMAB11.SA	ETF atrelado ao Tesouro IPCA+ — expectativa de risco fiscal e inflacionário




Figura 1 — série histórica do Ibovespa no período analisado, com a forte valorização observada a partir do final de 2025.

2.1. Por que ETFs em vez das séries oficiais

Incorporar juros e inflação ao modelo esbarra em um problema prático: as séries oficiais de taxas governamentais sofrem com instabilidade de API, atrasos de publicação e buracos no histórico — nenhum deles compatível com um pipeline que roda diariamente e precisa de dados alinhados ao pregão.

A solução foi usar dois ETFs listados na B3 como proxies de mercado. O LFTS11 acompanha títulos pós-fixados atrelados à Selic e reflete o custo de oportunidade do capital no curtíssimo prazo. O IMAB11 acompanha o Tesouro IPCA+ e carrega a expectativa do mercado quanto a risco fiscal e perda de poder de compra. Ambos têm liquidez diária e seguem o mesmo calendário do índice-alvo, o que elimina qualquer desalinhamento de datas.

2.2. Indicadores técnicos

Os modelos de classificação recebem, além das cotações, três indicadores calculados sobre a própria Bovespa pela biblioteca ta:

- **RSI (14 períodos)** — mede o momentum de sobrecompra e sobrevenda.

- **Distância para a SMA-15** — calculada como $(\text{Bovespa} / \text{SMA15}) - 1$, mede o afastamento em relação à tendência de médio prazo.
- **Largura das Bandas de Bollinger (20 períodos)** — quantifica o regime de volatilidade vigente.

A lógica é dar à rede não apenas o nível dos preços, mas também o contexto em que esse nível se encontra: um índice em 140 mil pontos após uma alta de três semanas é uma situação bem diferente de um índice no mesmo patamar depois de uma correção.

3. Preparação dos dados

Tratamento de feriados. Bolsas de países diferentes fecham em dias diferentes. Quando Xangai para por um feriado local e a B3 opera normalmente, surge um buraco na matriz. O tratamento usa forward fill (ffill), repetindo a última cotação conhecida — o que equivale a dizer que, sem pregão, o preço não mudou — seguido de um dropna() que elimina as primeiras linhas ainda incompletas.

Escalonamento. As variáveis convivem em ordens de grandeza radicalmente distintas: a Bovespa na casa das centenas de milhares de pontos, o dólar em torno de 5. Sem normalização, a rede trata o índice como se ele fosse o único sinal relevante e os gradientes explodem. Todas as variáveis passam por MinMaxScaler, com um normalizador separado para o alvo (scaler_target), necessário para reverter a previsão à escala de pontos ao final.




Figura 2 — as variáveis em escala original. A Bovespa domina completamente o gráfico e as demais séries ficam achatadas junto ao eixo — a razão prática pela qual a normalização é obrigatória.

Separação treino/teste. A divisão é de 80% para treino e 20% para teste, estritamente cronológica e sem embaralhamento (shuffle=False). Embaralhar uma série temporal permitiria que o modelo treinasse com dados do futuro e fosse avaliado no passado, inflando artificialmente o desempenho.

Janelas deslizantes. Cada amostra de entrada é uma janela de 7 dias úteis (time_steps = 7) de todas as variáveis, e o alvo é o fechamento do dia seguinte. Sete dias correspondem a pouco mais de uma semana de pregão — horizonte curto o bastante para preservar o contexto recente sem diluí-lo em ruído antigo.

4. Arquiteturas de rede

4.1. Regressão

A primeira versão do trabalho comparou quatro arquiteturas sobre a mesma base — MLP, CNN (Conv1D), LSTM e GRU. O GRU apresentou o melhor equilíbrio entre desempenho e custo de treinamento, e foi o escolhido para a versão definitiva:




Figura 3 — desempenho do MLP no conjunto de teste. A rede densa aprende o nível médio da série, mas não acompanha a trajetória — evidência de que a estrutura temporal precisa ser modelada explicitamente.

```
GRU(units=128, input_shape=(7, n_features))
Dropout(0.2)
Dense(1)

# loss='mean_squared_error', optimizer='adam'
# epochs=100, batch_size=32, validation_split=0.1, shuffle=False
```

O Dropout de 20% desliga aleatoriamente parte das conexões a cada passo de treino, o que reduz a chance de a rede decorar o histórico em vez de aprender o padrão. A camada Dense final, com um único neurônio e sem ativação, devolve o valor contínuo previsto — ainda em escala normalizada, revertido depois por `scaler_target.inverse_transform()`.




Figura 4 — evolução do erro ao longo das 100 épocas de treino do GRU. As duas curvas caem juntas e estabilizam, sem a divergência entre treino e validação que caracterizaria overfitting.

4.2. Classificação

Os modelos de 3 e 5 classes compartilham a mesma arquitetura, mudando apenas o número de neurônios na saída:

```
GRU(50, return_sequences=True) → Dropout(0.2)
GRU(50, return_sequences=False) → Dropout(0.2)
Dense(25, activation='relu')
Dense(N, activation='softmax') # N = 3 ou 5

# loss='categorical_crossentropy', optimizer='adam'
# epochs=100, batch_size=32, validation_split=0.1
```

O empilhamento de duas camadas GRU permite que a primeira extraia padrões locais dentro da janela e a segunda os condense em um vetor de contexto. A ativação softmax na saída garante que as previsões somem 100%, transformando o resultado em uma distribuição de probabilidade entre os cenários — e não em um veredito seco.

5. Métricas de avaliação

Métrica	Papel no projeto
RMSE	Raiz do erro quadrático médio; penaliza fortemente os erros grandes
MAE	Erro médio absoluto, em pontos do índice — a leitura mais intuitiva do desvio
MSE	Erro quadrático médio, usado também como função de perda no treino
EVS	Explained Variance Score: quanto da variância da série o modelo consegue explicar
MDA	Mean Directional Accuracy: percentual de acerto na direção do movimento

O MDA não existe nativamente no scikit-learn e foi implementado manualmente:

```
def mda(actual, predicted):  
    return np.mean((np.sign(actual[1:] - actual[:-1]) ==  
                    np.sign(predicted[1:] - predicted[:-1])).astype(int))
```

A função compara o sinal da variação real com o sinal da variação prevista, dia a dia. Ele foi tratado como métrica de primeira classe por um motivo prático: no mercado, acertar a direção do movimento costuma valer mais do que cravar a magnitude. Um modelo que erra 2.000 pontos mas acerta consistentemente a direção é operacionalmente mais útil do que um que fica próximo do valor nominal e erra o sentido.

6. Lógica das classes

O alvo da classificação não é o preço, mas a variação percentual em relação ao fechamento anterior. Os limiares foram definidos para separar movimento real de ruído de mercado.

6.1. Modelo de 3 classes

Classe	Condição	Significado
Baixa	Retorno < -0,2%	Fechamento abaixo do limite inferior
Neutro	Entre -0,2% e +0,2%	Zona de consolidação e indecisão
Alta	Retorno > +0,2%	Fechamento acima do limite superior

6.2. Modelo de 5 classes

Classe	Condição	Significado
Baixa Forte	Retorno $\leq$ -1,0%	Queda expressiva
Leve Baixa	Entre -1,0% e -0,2%	Correção controlada
Neutro	Entre -0,2% e +0,2%	Sem tendência definida
Leve Alta	Entre +0,2% e +1,0%	Crescimento marginal
Alta Forte	Retorno > +1,0%	Rompimento de resistência

A versão de 5 classes permite algo que a de 3 não alcança: estimar o risco de um dia atípico. Somando as probabilidades dos dois extremos, o modelo entrega uma leitura direta da chance de movimento violento — informação de gestão de risco, não de direção.

7. Resultados: o impacto das variáveis macro domésticas

A contribuição central deste trabalho está na inclusão progressiva das variáveis domésticas. Foram avaliados três cenários: apenas variáveis globais, globais mais juros, e globais mais juros e inflação.

Métrica	Cenário base (sem juros)	Com juros (Selic)	Com juros + inflação
MDA (acurácia direcional)	42,95%	52,34%	51,67%
MAE (erro médio absoluto)	8.603 pts	8.140 pts	5.262 pts
RMSE	9.271 pts	8.826 pts	6.159 pts
EVS Score	87,69%	82,52%	83,92%

Os números revelam um trade-off clássico de Machine Learning: a rede desloca o foco entre assertividade direcional e precisão absoluta de precificação, conforme as variáveis que recebe.

O ganho direcional. A inclusão isolada da taxa de juros elevou o MDA de 42,95% para 52,34%, rompendo a barreira do acaso. O modelo aprendeu uma relação econômica conhecida: picos de juros de curtíssimo prazo drenam liquidez da renda variável, porque o capital migra para o pós-fixado. Essa é a configuração indicada para estratégias de trend following, em que importa o sentido do movimento.

O ganho de precificação. A adição do IPCA+ funcionou como âncora. O ruído extra reduziu marginalmente o MDA, para 51,67%, mas o erro médio absoluto caiu de 8.140 para 5.262 pontos — uma redução de aproximadamente 35%. Ao incorporar o prêmio de risco inflacionário, o modelo deixou de produzir projeções extremas e passou a estimar com mais fidelidade o valor justo do índice. É a configuração indicada para alocação estrutural e análise de valuation.




Figura 5 — visão completa da série: em verde o período de treino, em azul os valores reais do período de teste e em vermelho a previsão do modelo V2.




Figura 6 — detalhe do conjunto de teste. A previsão acompanha os movimentos do índice com defasagem pequena, e o descolamento se concentra nos picos — comportamento esperado em regressão sobre séries voláteis.

A escolha entre as duas configurações, portanto, não é uma questão de qual modelo é melhor, mas de qual pergunta se quer responder. E ambas confirmam a premissa de fundo do trabalho: a bolsa se comporta como um derivativo complexo da curva de juros real do país.

8. Estrutura do repositório

Arquivo	Função
Previsao Multivariada.ipynb	Versão 1 — EDA e benchmark entre MLP, CNN, LSTM e GRU (7 variáveis)
Previsao Multivariadas V2.ipynb	Versão 2 — GRU de regressão com juros e inflação (9 variáveis)
Previsao 3 Classes.ipynb	Treinamento do classificador GRU de 3 classes
Previsao 5 Classes.ipynb	Treinamento do classificador GRU de 5 classes
Previsao Diaria.ipynb	Previsão diária de ponto, carregando o modelo salvo
Previsao Diaria 3 Classes.ipynb	Previsão diária com o modelo de 3 classes
Previsao Diaria 5 Classes.ipynb	Previsão diária com o modelo de 5 classes

A pasta modelos/ não é versionada: ela é criada na primeira execução dos notebooks de treinamento e recebe a arquitetura em JSON, os pesos em formato .weights.h5 e os normalizadores serializados com joblib. Isso mantém o repositório leve e garante que quem clonar o projeto treine com dados atualizados.

A separação entre notebooks de treinamento e notebooks de previsão diária é intencional. O treinamento é caro e roda uma vez; a previsão diária apenas carrega os artefatos salvos, baixa as últimas cotações e devolve o veredito em segundos.

9. Como executar

Ambiente e dependências:

```
conda create -n SeriesTemporais python=3.12
conda activate SeriesTemporais
pip install yfinance pandas numpy scikit-learn tensorflow ta \
        joblib matplotlib seaborn plotly pmdarima watermark
```

Treinamento, executado uma única vez, na ordem:

- Previsao Multivariadas V2.ipynb — gera o modelo de regressão e os scalers
- Previsao 3 Classes.ipynb — gera o classificador de 3 classes
- Previsao 5 Classes.ipynb — gera o classificador de 5 classes

Uso rotineiro, com os modelos já salvos:

- Previsao Diaria.ipynb — ponto de fechamento estimado
- Previsao Diaria 3 Classes.ipynb — veredito direcional com probabilidades
- Previsao Diaria 5 Classes.ipynb — veredito completo com zonas de preço e risco de volatilidade

9.1. Exemplo de saída

```
=====
RADAR BOVESPA: 5 CLASSES (RISCO & VOLATILIDADE)
=====
Cotação Atual Base: 177356 pts (Data: 20/05/2026)
Veredito Principal: BAIXA FORTE (menor que -1.0%)

RAIO-X DE PROBABILIDADES:
Alta Forte:      7.89%
Leve Alta:      9.74%
Neutro:         25.10%
Leve Baixa:     15.10%
Baixa Forte:    42.17%

-----
Risco de Movimento Violento (Extremos): 50.06%

ZONAS DE PREÇO (PRÓXIMO DIA ÚTIL):
Acima de 179129 pts      -> ALTA FORTE
Entre 177710 e 179129 pts -> LEVE ALTA
Entre 177001 e 177710 pts -> NEUTRO
Entre 175582 e 177001 pts -> LEVE BAIXA
Abaixo de 175582 pts     -> BAIXA FORTE
=====
```

10. Desafios técnicos e soluções

Métrica ausente na biblioteca. O MDA não faz parte do scikit-learn e precisou ser codificado do zero a partir da comparação de sinais entre variações reais e previstas.

Valores nominais em camadas densas. Uma versão inicial submetia os valores brutos ao `fit()`, o que impedia a convergência. Foi necessário garantir que apenas os dados escalados chegassem ao treinamento — um erro silencioso, já que o modelo treina sem lançar exceção, apenas sem aprender.

Salvamento de pesos no TensorFlow 2.16+. A versão nova passou a exigir nomenclatura estrita e lançava `ValueError` no `save_weights()`. A solução foi migrar a extensão de `.h5` para `.weights.h5` e salvar a arquitetura separadamente com `to_json()`.

Captura de taxas governamentais. A instabilidade das APIs oficiais inviabilizou o uso direto das séries de juros e inflação, resolvido pela substituição por ETFs de renda fixa listados na B3, conforme detalhado na seção 2.1.

11. Conclusões

Interdependência global confirmada. A Bovespa apresenta forte correlação com Xangai, o S&P 500 e os contratos de minério e petróleo. As redes recorrentes capturaram essas interações não lineares de forma mais eficaz do que ARIMA e SARIMAX, que dependem de uma linearidade frequentemente ausente nos dados de mercado.

Classificação supera regressão em aplicabilidade. Modelos probabilísticos por zonas entregam previsões estrategicamente mais seguras do que a estimativa de um ponto nominal único. Saber que existe 42% de chance de queda forte orienta melhor uma decisão de risco do que um número exato apresentado sem margem.

O pré-processamento é decisivo. Normalização e tratamento de feriados internacionais não são detalhes de implementação: sem eles, os modelos simplesmente não convergem. Boa parte do resultado final foi construída antes da primeira linha de arquitetura.

A macro doméstica é o diferencial do trabalho. A curva de juros define o edge direcional; a inflação implícita ancora a precificação. Foi a inclusão dessas duas variáveis que levou o modelo do patamar do acaso para um resultado consistente, e é ela que sustenta a conclusão central: a bolsa de valores opera como um derivativo complexo da curva de juros real do país.

Aviso: este projeto tem finalidade exclusivamente acadêmica e educacional. As previsões geradas não constituem recomendação de investimento.